Prédiction des Charges Médicales

Machine Learning / Régression

Présentée par : Dhouib Eya

Professeurs : Mr. Ben Hamed Bassem

1 MR ISI . 2025-2026

Plan

01 Contexte & Objectif

02 Dataset

03 Pipeline du projet & Résultats principaux

04 Observations clés

05 Limites identifiées

01 Contexte & objectif

Ce projet s’inscrit dans le domaine du Machine Learning appliqué à la santé, avec pour objectif de prédire les charges médicales individuelles à partir de caractéristiques personnelles .

Nous avons commencé par une analyse exploratoire des données afin de comprendre leur structure et identifier les relations importantes.
Ensuite, un prétraitement a été réalisé pour préparer les données à la modélisation.
Plusieurs modèles de régression ont été entraînés et évalués à l’aide de différentes métriques. Enfin, une sélection de variables a été effectuée pour améliorer les performances et simplifier le modèle.

caractéristiques personnelles:

- Age
- Sexe
- IMC
- Nombre d'enfants
- statut fumeur
- Région

02 Dataset

Datasets utilisés : medical-charges.csv

*** Premières lignes ***

	age	sex	bmi	children	smoker	region	charges
0	19	female	27.900	0	yes	southwest	16884.92400
1	18	male	33.770	1	no	southeast	1725.55230
2	28	male	33.000	3	no	southeast	4449.46200
3	33	male	22.705	0	no	northwest	21984.47061
4	32	male	28.880	0	no	northwest	3866.85520

*** Dernières lignes ***

	age	sex	bmi	children	smoker	region	charges
1333	50	male	30.97	3	no	northwest	10600.5483
1334	18	female	31.92	0	no	northeast	2205.9808
1335	18	female	36.85	0	no	southeast	1629.8335
1336	21	female	25.80	0	no	southwest	2007.9450
1337	61	female	29.07	0	yes	northwest	29141.3603

1338 Lignes

×

7 Colonnes

03 Pipeline du projet

Structure du projet :

1. Introduction et Description du Dataset
2. Importation des Librairies
3. Chargement des Données
4. Phase 1 — Analyse Exploratoire (EDA)
   - 4.1 Analyse Univariée
   - 4.2 Analyse Bivariée
   - 4.3 Analyse Multivariée
   - 4.4 Détection des Outliers
5. Phase 2 — Nettoyage et Prétraitement
   - 5.1 Valeurs Manquantes
   - 5.2 Doublons
   - 5.3 Encodage des Variables Catégorielles
   - 5.4 Feature Scaling
   - 5.5 Train/Test Split
6. Phase 3 — Modélisation
   - 6.1 Linear Regression (OLS)
   - 6.2 Ridge Regression (L2)
   - 6.3 Lasso Regression (L1)
   - 6.4 ElasticNet Regression (L1 + L2)
7. Phase 4 — Évaluation des Modèles
8. Phase 5 — Sélection de Features
9. Phase 6 — Comparaison All Features vs Selected Features
10. Phase 7 — Conclusion

03 Pipeline du projet

Phase 1 — Analyse Exploratoire (EDA)

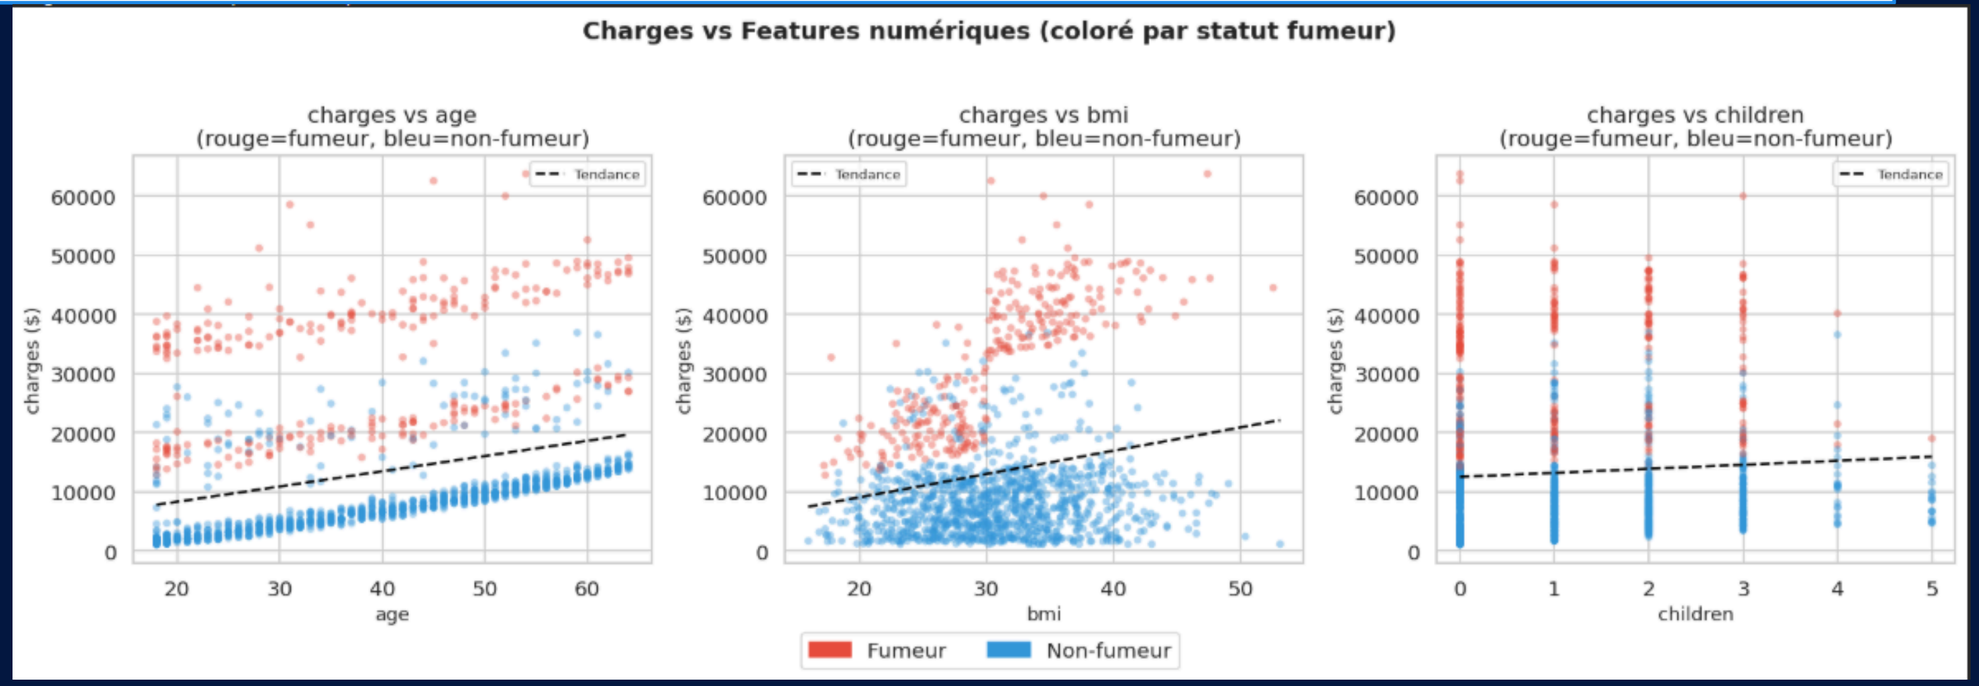

① Charges vs Age

💡 Observation
- La ligne de tendance monte → relation positive
- Les points rouges (fumeurs) sont beaucoup plus hauts que les bleus

➡️ l'âge influence les charges
➡️ le statut fumeur amplifie fortement cet effet

② Charges vs BMI

💡 Observation
- Tendance légèrement croissante
- Grande dispersion des points
- Les fumeurs (rouge) ont des valeurs très élevées

➡️ interaction BMI × smoker très importante
➡️ le BMI seul n'explique pas tout, mais combiné avec le tabac → effet fort

③ Charges vs children

💡 Observation
- Ligne de tendance presque plate
- Pas de variation claire selon le nombre d'enfants

➡️ variable peu importante pour la prédiction

03 Pipeline du projet

Phase 1 — Analyse Exploratoire(EDA)

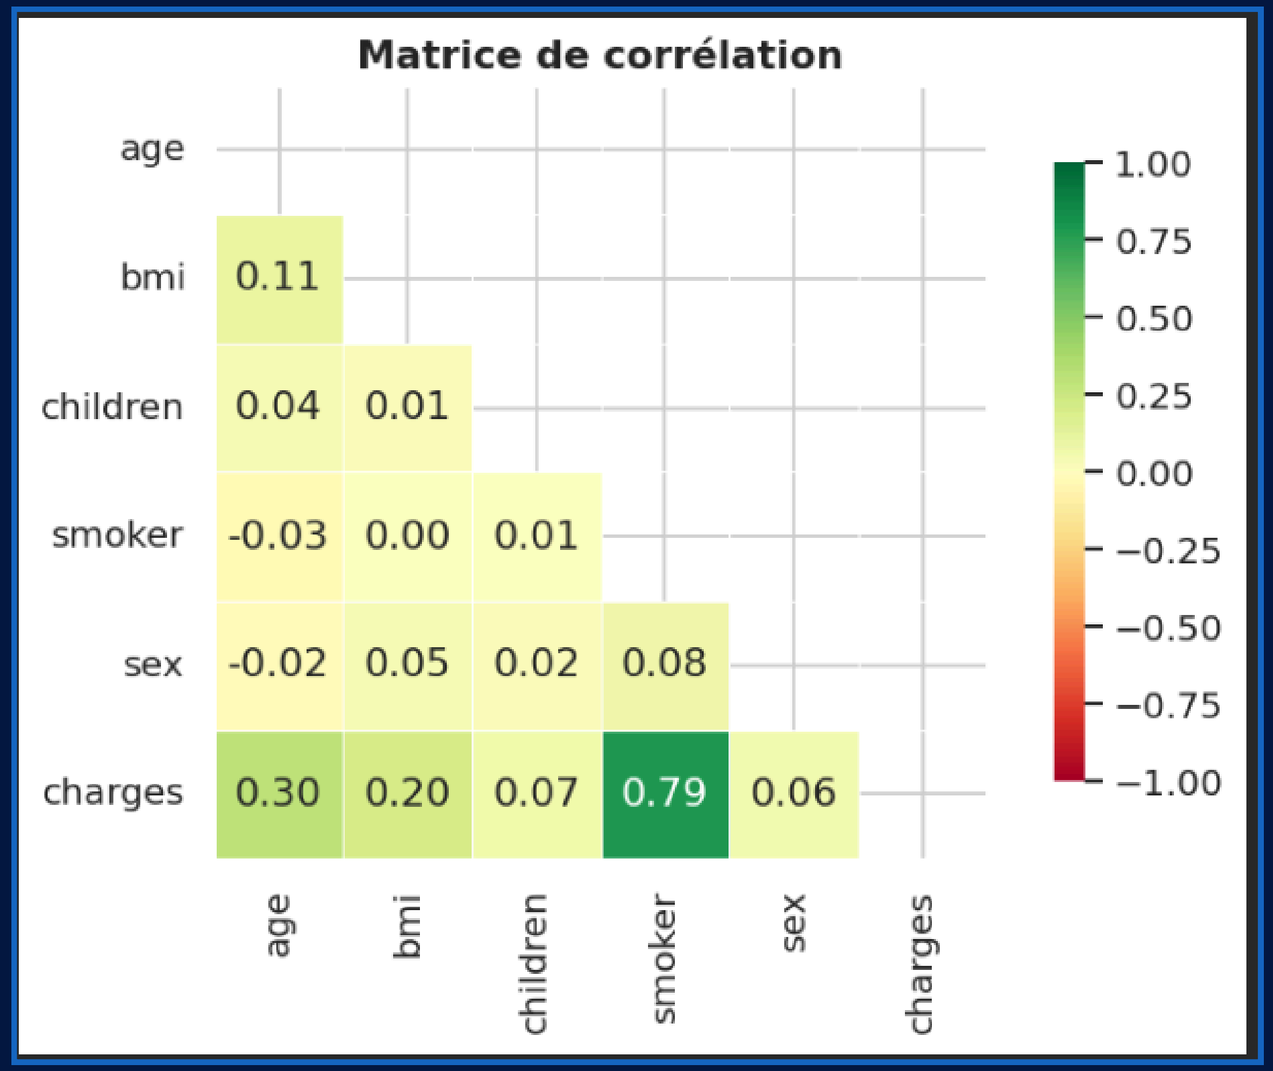

Matrice de correlation

💡 Observations :

- Corrélation très forte entre smoker et charges → 0.79
- Corrélation modérée : age (0.30) et bmi (0.20)
- Très faible impact : children et sex

➡️ Le tabagisme est le facteur dominant des charges médicales.

➡️ Les modèles devront prioriser cette variable.

03 Pipeline du projet

Phase 2 — Nettoyage et Prétraitement (Cleaning & Preprocessing)

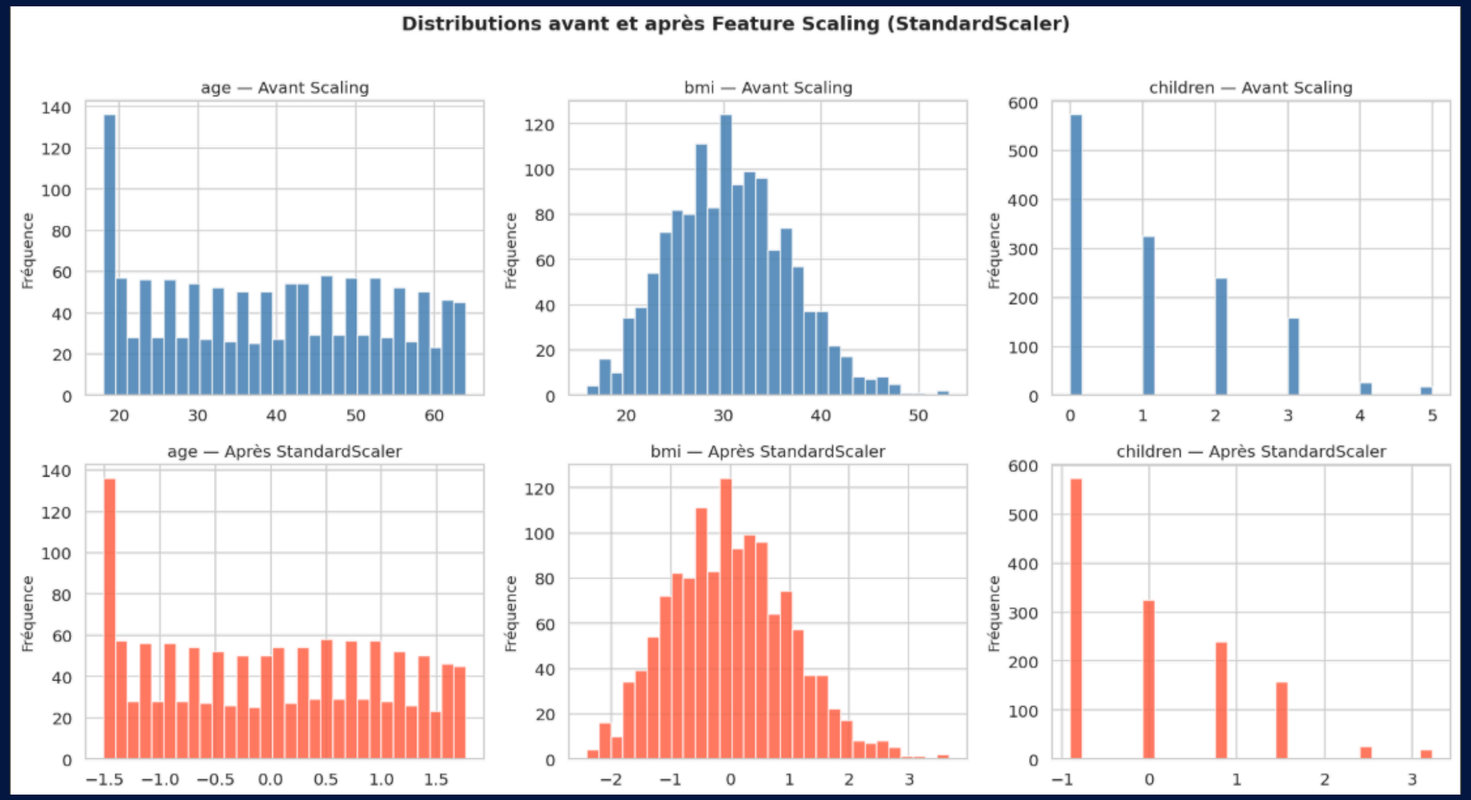

Feature Scalling

💡 **Observations :**

- Ce graphique compare les distributions des variables numériques (age, bmi, children) avant et après l'application du StandardScaler.
- **Avant scaling** : les variables ont des échelles très différentes (ex. children entre 0 et 5, age entre 18 et 64, BMI entre 15 et 53).
- **Après scaling** : toutes les variables sont centrées autour de 0 avec un écart-type de 1. Elles sont maintenant sur la même échelle.

➡️ Le StandardScaler a réussi à normaliser les variables numériques.
Cela est essentiel pour les modèles de régression (surtout Ridge, Lasso et ElasticNet) afin d'éviter que certaines variables dominent les autres à cause de leur échelle.

03 Pipeline du projet

Phase 2 — Nettoyage et Prétraitement (Cleaning & Preprocessing)

detection des doublons

→ suppression de la ligne dupliquée
→ Nouvelle dimension du dataset : (1337, 7)

Encodage

Les modèles de Machine Learning
(Linear, Ridge, Lasso...)
ne comprennent que des nombres

Split Train / Test

→ **y_train** : 1069 valeurs
→ **y_test** : 268 valeurs
random_state=42 → reproductibilité garantie

Aperçu des lignes dupliquées :

	age	sex	bmi	children	smoker	region	charges
195	19	male	30.59	0	no	northwest	1639.5631
581	19	male	30.59	0	no	northwest	1639.5631

```
Split Train/Test :
  - X_train : (1069, 8)  |  y_train : (1069,)
  - X_test  : (268, 8)   |  y_test  : (268,)
  - ratio   : 80 % / 20 %  |  random_state=42
```

03 Pipeline du projet

Phase 3 — Modélisation (Linear Regression + Régularisation)

- ***Définition des Métriques***

Métrique	Notation	Définition	Ce que signifie un bon résultat
RMSE	Root Mean Square Error	Erreur quadratique moyenne (en dollars). Punition forte sur les grosses erreurs.	Plus petit = mieux
MAE	Mean Absolute Error	Erreur absolue moyenne (en dollars). Plus facile à interpréter.	Plus petit = mieux
R^2	Coefficient de détermination	Proportion de variance expliquée par le modèle (entre 0 et 1).	Plus proche de 1 = mieux
CV R^2	Cross-Validation R^2	Moyenne du R^2 sur 5 folds de validation croisée. Mesure la **stabilité** du modèle.	Plus élevé + faible écart = mieux
α (Alpha)	Paramètre de régularisation	Contrôle la force de la pénalisation. Plus α est grand, plus le modèle est simplifié.	Valeur optimale trouvée par CV

03 Pipeline du projet

Phase 3 — Modélisation (Linear Regression + Régularisation)

- ***Description des Modèles***

Modèle	Type de Modèle	Description	Avantage principal
Linear Regression	Régression Linéaire classique	Modèle de base qui minimise l'erreur sans aucune pénalisation.	Simple et interprétable
Ridge Regression	Régression avec régularisation L2	Ajoute une pénalité sur les grands coefficients pour éviter le surapprentissage.	Meilleure stabilité et généralisation
Lasso Regression	Régression avec régularisation L1	Peut réduire certains coefficients **à zéro** (sélection de variables automatique).	Permet de simplifier le modèle
ElasticNet	Combinaison L1 + L2	Combine les avantages de Ridge et Lasso.	Flexible quand il y a beaucoup de variable

Objectif :

Comparer les performances des modèles linéaires classiques et ceux avec régularisation, tout en analysant l'impact des hyperparamètres (α).

03 Pipeline du projet

Phase 3 — Modélisation (Linear Regression + Régularisation)

- ***Analyse des Coefficients & Régularisation***

```
=== Tableau Comparatif des Coefficients ===
                  LinearRegression     Ridge     Lasso  ElasticNet
Feature
smoker                   23077.76  22808.25  22899.26    22899.26
age                       3484.65   3475.52   3467.05     3467.05
bmi                       1943.50   1934.22   1881.51     1881.51
region_southeast           -838.92   -801.52   -378.97     -378.97
region_southwest           -659.14   -646.56   -229.39     -229.39
children                    642.34    643.97    619.30      619.30
region_northwest           -391.76   -386.67     -0.00       -0.00
sex                        -101.54    -82.49     -0.00       -0.00
Linear Regression      → CV R² : 0.7258 ± 0.0253  | folds : [0.6941 0.7636 0.7211 0.7058 0.7442]
Ridge                  → CV R² : 0.7259 ± 0.0252  | folds : [0.6926 0.7638 0.7221 0.7079 0.743 ]
Lasso                  → CV R² : 0.7260 ± 0.0251  | folds : [0.6938 0.7641 0.7216 0.7073 0.7431]
ElasticNet             → CV R² : 0.7260 ± 0.0251  | folds : [0.6938 0.7641 0.7216 0.7073 0.7431]
```

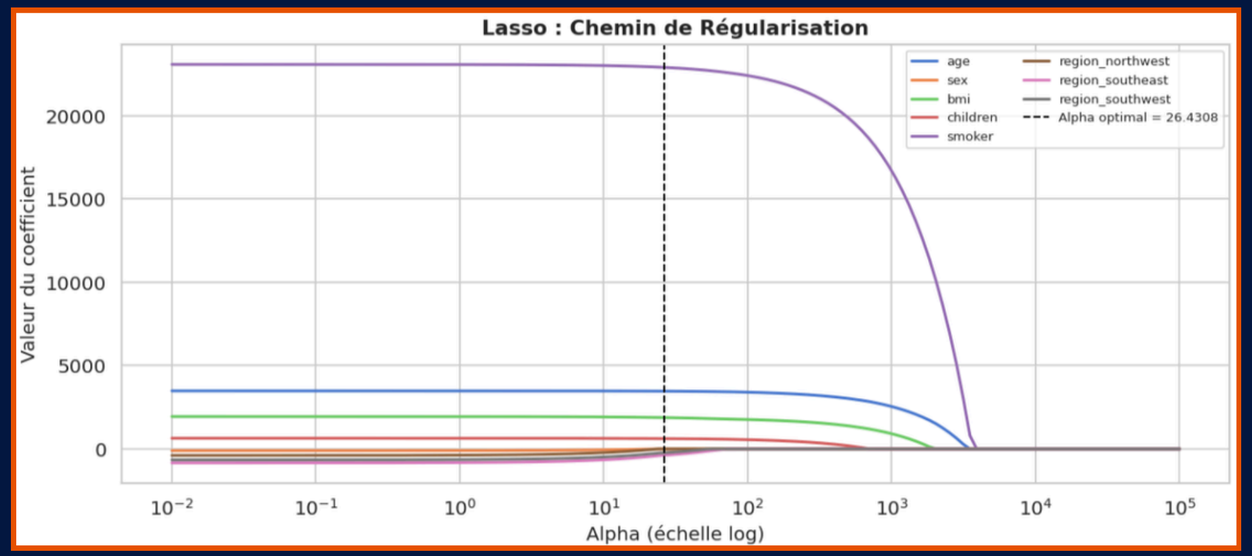

1. Variable la plus influente :
smoker reste la variable dominante dans tous les modèles avec un coefficient autour de **23 000** .

2. Effet du Lasso :
Le Lasso a annulé complètement les coefficients de deux variables :
- sex
- region_northwest

→ Cela confirme que ces deux features apportent très peu d'information prédictive

03 Pipeline du projet

Phase 3 — Modélisation (Linear Regression + Régularisation)

- ***Analyse des Coefficients & Régularisation***

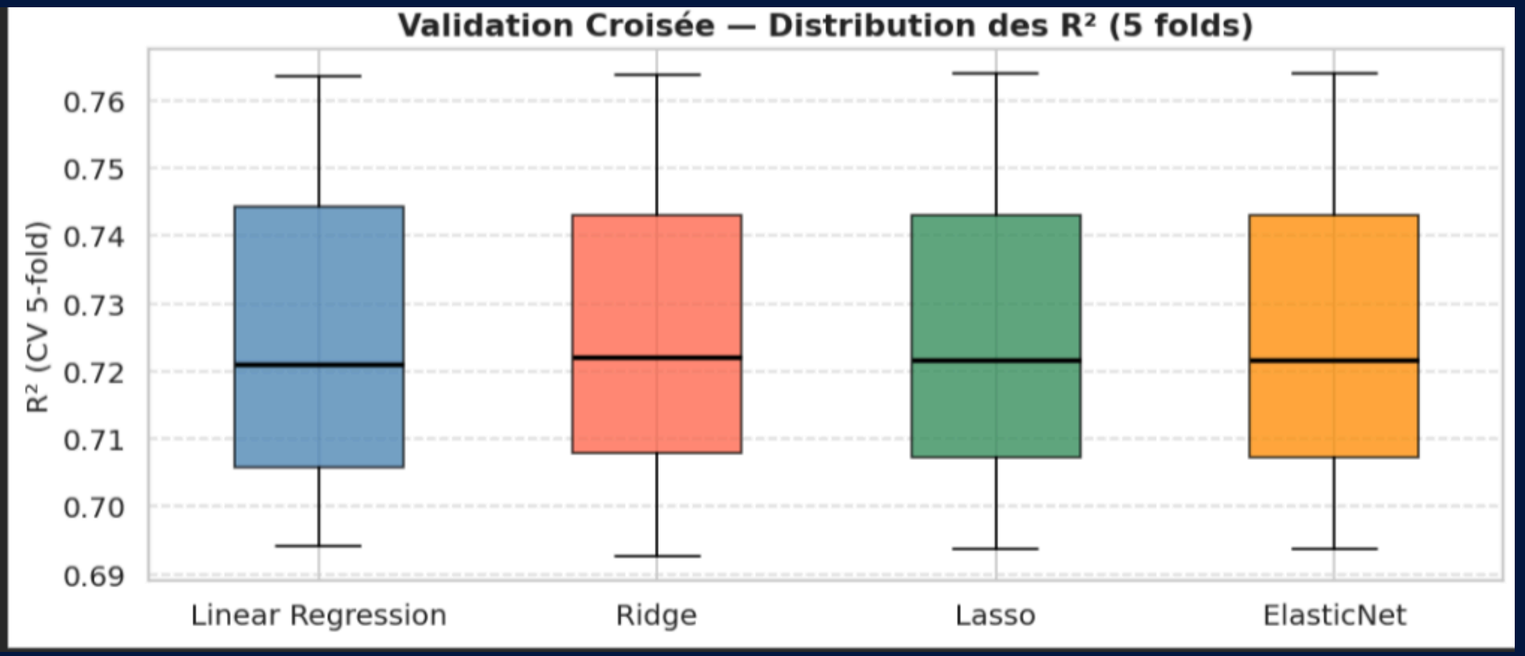

Validation Croisée (5-Fold Cross-Validation) :

- Technique pour évaluer la robustesse du modèle de façon fiable.
- Le jeu d'entraînement est divisé en 5 parties.
- On entraîne et teste le modèle 5 fois en changeant la partie de test à chaque fois.
- CV R^2 = Moyenne des R^2 sur les 5 folds + écart-type.

→ Avantage :
Permet d'avoir une estimation plus stable que le simple R^2 sur le jeu de test.

03 Pipeline du projet

Phase 4 — Évaluation des Modèles

- ***Résultats des Modèles***

Modèle	RMSE Test	MAE Test	R^2 Test	CV R^2 (5-fold)	Meilleur α
Linear Regression	**5956.34**	**4177.05**	**0.8069**	**0.7258 ± 0.0253**	**-**
Ridge Regression	5987.39	4210.18	0.8049	0.7259 ± 0.0252	1.98
Lasso Regression	5993.51	4198.61	0.8045	0.7260 ± 0.0251	26.43
ElasticNet	5993.51	4198.61	0.8045	0.7260 ± 0.0251	26.43 (l1_ratio=1)

💡 **Observations :**

- Les quatre modèles obtiennent des performances très proches, avec un R^2 Test autour de 0.80.
- La Régression Linéaire (OLS) présente les meilleurs résultats sur le jeu de test (meilleur RMSE, MAE et R^2 Test).
- Les modèles avec régularisation (Ridge, Lasso et ElasticNet) donnent des performances légèrement inférieures mais très similaires entre eux.
-

➡️ **Conclusion :**

La Régression Linéaire simple est le modèle le plus performant dans ce cas. La régularisation (Ridge, Lasso, ElasticNet) n'apporte pas d'amélioration significative de la performance et rend même les prédictions légèrement moins précises sur le jeu de test.

Ce résultat s'explique par la taille modeste du dataset et l'absence de forte multicolinéarité .

03 Pipeline du projet

Phase 5 — Sélection de Features (Feature Selection)

- ***Contenu :***

Nous avons appliqué trois méthodes de sélection de variables pour identifier les features les plus importantes :

1. Backward Elimination (basée sur les p-values)
2. RFE (Recursive Feature Elimination)
3. Analyse des coefficients Lasso

- ***Objectif :***

Réduire le nombre de variables tout en conservant (ou en améliorant) les performances du modèle.

- ***Résultats des Méthodes***

Méthode	Features Retenues	Features Supprimées
Backward Elimination	age, bmi, children, smoker	sex + 3 régions
RFE	age, bmi, children, smoker	sex + 3 régions
Lasso	age, bmi, children, smoker + 2 régions	sex, region_northwest

➡️ Conclusion :

- Les 4 variables les plus importantes sont : age, bmi, children et smoker
- Cela permet de simplifier le modèle tout en conservant l'essentiel du pouvoir prédictif.

04 Observations Clés

Variable Smoker

La variable smoker est largement dominante, présentant la corrélation la plus forte avec les charges et le coefficient le plus élevé dans tous les modèles.

Âge et IMC

L'âge et l'IMC ont un impact positif significatif sur les charges médicales.

Variables Sex et Region

Les variables sex et region apportent très peu d'information prédictive.

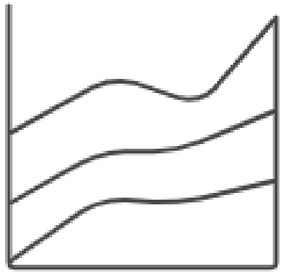

Performances des Modèles

Les quatre modèles de régression donnent des performances très proches.

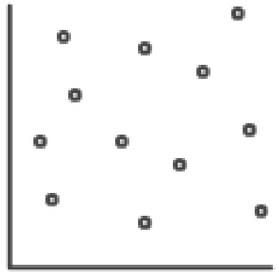

Régression Linéaire Simple

La Régression Linéaire simple est le modèle le plus performant dans ce cas.

05 Limites identifiées

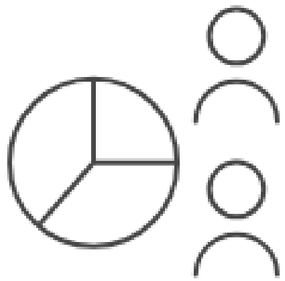

Taille du dataset

Seulement 1 337 observations, ce qui limite la généralisation du modèle sur une population plus large.

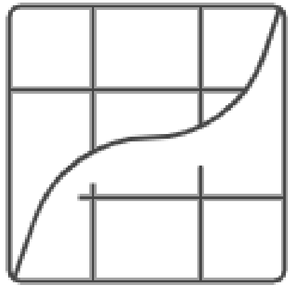

Hypothèse de linéarité

Les modèles supposent des relations linéaires, alors que l'interaction bmi × smoker est clairement non-linéaire.

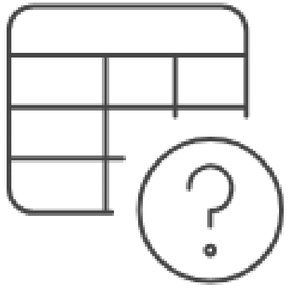

Variables manquantes

Absence de données importantes telles que les antécédents médicaux, le revenu, le mode de vie ou l'historique de santé.

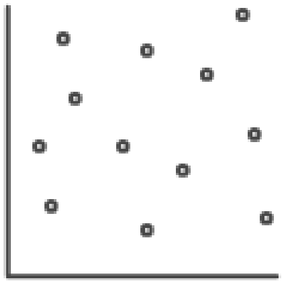

Hétéroscédasticité

La variance des résidus augmente avec les charges élevées, ce qui viole une des hypothèses de base de la régression linéaire.

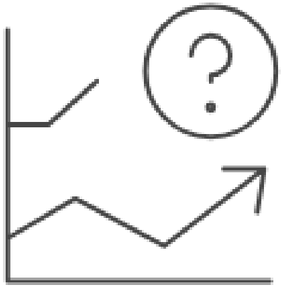

Pas de transformation de la cible

La variable charges n'a pas été transformée (ex. log), ce qui pourrait améliorer les performances.